正则表达式快速参考手册

胡志飞

 $<\!WisdomFusion[at]gmail[dot]com\!>$

2012年之旧文重拾于 2016年 2月 26日 version 0.1.0

	录				6.2.2	Python	20
					6.2.3	PHP PCRE	20
1	简介	1			6.2.4	sed & awk	20
2	基本语法	2			6.2.5	grep	20
	CENT VIA IN				6.2.6	Swift	20
3	高级语法	8			6.2.7	Java	20
4	拳些 例 子吧!	44			6.2.8	.NET Framework 正则表达式	20
4	华空例 丁吧:	11			6.2.9	JavaScript	21
5	正则表达式"流派"	12			6.2.10	Adobe Dreamweaver 表格处理	21
					6.2.11	VBA 中使用正则表达式	21
6	应用场景	15			6.2.12	GREP for Adobe InDesign	22
	6.1 正则表达式工具箱	15			6.2.13	神的编辑器 GNU Emacs 之正则神器	22
	6.2 应用案例	20			J		
	6.2.1 Perl 正则表达式王国	20	7	后记			22

1 简介 Introduction

文字处理无处不在无时不有,日常工作和学习大多数任务都和文字息息相关,编辑们写文章、整理资料,开发人员编码、处理用户提交的数据或请求接口数据,等等,这些都是以字符和字符串相关的任务,既然如些,掌握一个快速文字处理的方法就变得很有必要。

正则表达式,(Regular Expression,在代码中常简写为 regex、regexp 或 RE),计算机科学的一个概念。正则表达式使用字符来描述、匹配一系列符合某个句法规则的字符串。在很多文本编辑器里,正则表达式通常被用来检索、替换那些符合某个模式的文本。许多程序设计语言都支持利用正则表达式进行字符串操作。例如,在 Perl[®]中就内建了一个功能强大的正则表达式引擎。正则表达式这个概念最初是由 Unix 中的工具软件(例如 sed[®]和 grep[®])普及开的。

需要注意的是,用什么工具,用什么编辑语言,正则表达式的语法有些差别,特性的支持也参差不齐,称之为正则表达式"流派"(第5部分详述),所以要单独参考工具和编程语言本身的文档才行。本文档旨在给大家一个通用的、概括的正则表达式宏观印象,辅以实例和应用案例,同时针对个别常用但又不易理解的特性,给大家作详细说明和总结,抛砖引玉。

期望本文档能给大家一个快速的参考,快速的掌握正则表达式这个棒棒哒效率工具,让大家平时工作学习中更加得心应手!◎

说明

我对排版及专业出版知之甚微,只是在平时笔记和文档时,哪怕是自己写的太乱的话也不乐意翻看,印象笔记里的东东又过于零碎,故把旧文完善并整排"。然而,专业领域知识因涉猎过多而不精,难保周全和准确,但只要在自己知识圈内,我会劲力完成尽可能规范和可靠的文档呈现给大家,并不断完善更新,请批评指正,共同提高。

"本文档 **2012** 年编写,现整拾,并加以完善。目前觉得 **Markdown**, **org-mode**适用于文本文档的快速编写,而 **Adobe InDesign** 和 **LaTeX** 适合更专业的文档 和书籍的图文混排及设计。

^①Perl被称为"实用报表提取语言"(Practical Extraction and Report Language),正则表达式特性的推动者,文本处理非常方便。

^②sed是一种 UNIX/Linux 平台下的轻量级流编辑器,日常一般用于处理文本文件。

[®]grep,global search regular expression and print out the line,是一种强大的文本搜索工具,它能使用正则表达式搜索文本,并把匹配的行打印出来。

2 基本语法 Basic Syntax

语法部分结合了自己的理解和对正则表达式应用的一些心得,分类有不当之处,请指正。因为是总结性的参考文档,所以这里使用"大表哥"形式展示,列出语法的同时,关键语法举了几个栗子加强理解。

特性	语法	描述	举个栗子
字符	除 [\^\$. ?*+() 以 外的任意字符	除了[\^\$. ?*+()以外的任意字符, {和}也是文字文本,除了下面说到的成对出现的量词语法,如 {n}和 {m,n}等。	a 匹配 about 中的 a
	字符转义	\t,\\?,*,\\+,\\.,\\\\\\\\\\\\\\\	\+ 匹配 + ; \?\- 匹配 ?-
	\n , \r 和 \t	Windows 文件格式换行符是\r\n, UNIX 文件格式换行符是\n, \t 匹配水平制表符	
	\cA 到 \cZ,	Ctrl + A 到 Ctrl + Z ,与 ASCII 字符 \x01 到 \x1A 等价	
	\ca 到 \cz		
	\a, \e, \f, \v	依次为警报(\xo7)、Esc字符(\x1B)、进纸符(\xoC)和 垂直制表符(\xoB)	
	\Q \E	文字文本范围,被包含在 \Q 和 \E 之间的文字,都被视为普通文字,如 [\^\$. ?*+(){} 也不再用转义了,这个最早是由 Perl 引入正则表达式的。	\Q+-*/\E 匹配的就是 +-*/
基本特性	. (点)	匹配除换行符之外的任意字符,有些正则表达式"流派"还 支持点是否匹配换行符的开关。	. 匹配 about 中的任意一个字符

(续表)

特性	语法	描述	举个栗子
	I	管道,或的关系,匹配 的左侧或右侧的字符串	abc def xyz 匹配 abc 或 def 或 xyz
字符类	[]	匹配字符类中列举的任意一个字符	[abc] 匹配 a 或 b 或 c [aeiou] 匹配任何一个英文元音字母 [.!?] 匹配 . 或! 或?
	[\^\]]	在字符类中,要匹配 ^-]\这几字符,得使用\转义	[\^\]] 匹配 ^ 或]
	[^]	排除型字符类, ^ (脱字符, caret) 紧跟 [之后, 可以把字符类中列举的字符排除匹配范围, 也就是所这个字符类将匹配任意一个不在列出字符范围内的字符	[^a-d] 匹配除了 a,b,c,d 之外的任意一个字符
	\d , \w , \s	\d 匹配数字,与 [0-9] 等价;\w 匹配任意一个字母或数字或下划线或汉字;\s 匹配任意一个空白符	[\d\s] 匹配一个数字或空白符
	\D , \W , \S	是 \d , \w 和 \s 的反义字符类。\D 匹配任意非数字的字符; \W 匹配任意不是字母、数字、下划线、汉字的字符; \S 匹配任意不是空白符的字符	\D 匹配任意非数字的字符
	[\b]	在字符类中, [\b] 为 Backspace 退格键字符	
POSIX	[:alnum:]	匹配所有大小写字母及数字	等价于 [o-9a-zA-Z]

(续表)

特性	语法	描述	举个栗子
	[:alpha:]	匹配所有大小写字母	等价于 <mark>[a-zA-Z]</mark>
	[:ascii:]	匹配所有 ASCII 字符,查看完整ASCII 字符列表	等价于 <mark>[\x01-\x7F]</mark>
	[:blank:]	匹配半角空格和制表符	等价于 <mark>[\t]</mark>
	[:cntrl:]	匹配所有 ASCII o 到 31 之间的控制符	等价于 <mark>[\x01-\x1F]</mark>
	[:digit:]	匹配所有数字	等价于 <mark>[0-9]</mark>
	[:graph:]	匹配所有可打印的字符	
	[:lower:]	匹配所有小写字母	等价于 <mark>[a-z]</mark>
	[:print:]	匹配所有可打印字符和空格	
	[:punct:]	匹配所有标点符号	
	[:space:]	空白字符	等价于 <mark>[\t\n\r\f\v]</mark>
	[:upper:]	匹配所有大写字母	等价于 <mark>[A-Z]</mark>
	[:word:]	字母、数字和下划线	等价于 <mark>[a-zA-Zo-9_]</mark>
	[:xdigit:]	匹配所有十六进制字符	等价于 <mark>[0-9a-fA-F]</mark>

(续表)

特性	语法	描述	举个栗子
锚点	^	匹配字符串开始位置或行首位置	单行模式下 [^] . 在 foo\nbar 中匹配 f ; 在多行模式下,同时还匹配换行后的 b
	\$	匹配字符串结尾位置或行尾位置	.\$ 在 foo\nbar 中匹配 r ; 在多行模式 下,同时还匹配换行符前的 0
	\A	字符串开头位置(类似^,但不受处理多行选项的影响)	\Ae 在 example 这个字符串中匹配开头的 e
	\Z	字符串结尾位置或行尾位置(不受处理多行选项的影响)	e\Z 在 example 这个字符串中匹配结尾的 e
	\b	单词分界位置,单词开头或结尾	.\b 在字符串 abc 中匹配 c
	\B	匹配不是单词开头或结尾的位置	\B.\B 在字符串 abc 中匹配 b
	\<	单词开头	
	\>	单词结尾	

(续表)

特性	语法	描述	举个栗子				
量词	?	前导字符重复零次或一次,贪婪的 [©] :当正则表达式中包含能接受重复的限定符时,通常的行为是(在使整个表达式能得到匹配的前提下)匹配尽可能多的字符。					
	??	前导字符重复零次或一次,非贪婪 [®] :当正则表达式中包含能接受重复的限定符时,通常的行为是(在使整个表达式能得到匹配的前提下)匹配尽可能少的字符。与贪婪相反。	abc?? 匹配 ab 或 abc				
	*	前导字符重复零次或更多次,贪婪的					
	*3	前导字符重复零次或更多次,非贪婪					
	+	前导字符重复一次或更多次,贪婪的					
	+?	前导字符重复一次或更多次,非贪婪					
	{n}	前导字符重复 n 次					
	To be continued						

^①贪婪模式:当正则表达式中包含能接受重复的限定符时,通常的行为是(在使整个表达式能得到匹配的前提下)匹配尽可能多的字符。考虑这个表达式: a.*b,它将会匹配最长的以 a 开始,以 b 结束的字符串。如果用它来搜索 aabab 的话,它会匹配整个字符串 aabab 。这被称为贪婪匹配。

[®]相反,非贪婪,即匹配尽可能少的字符,只要在量词后面加上一个问号?。如 a.*?b 匹配最短的,以 a 开始,以 b 结束的字符串。如果把它应用于 aabab 的话,它会 匹配 aab (第一到第三个字符)和 ab (第四到第五个字符)。

(续表)

特性	语法	描述	举个栗子
	{n,m}	前导字符重复 \mathbf{n} 到 \mathbf{m} 次,其中 $n >= 0$, $m >= n$	
	{n,}	前导字符重复 \mathbf{n} 次或更多次,其中 $n >= 0$	
	{,m}	前导字符最多重复 \mathbf{m} 次,基中 $m>=0$	
分组与	(regex)	匹配 regex,并捕获文本到自动命名的组里	(abc){3} 匹配 abcabcabc
反向引用	(?:regex)	匹配 regex,不捕获匹配的文本,也不给此分组分配组号	(?:abc){3} 匹配 abcabcabc , 无分组
	\1到\9	反向引用,用于重复搜索前面某个分组匹配的文本。例如,	(abc def)=\1 匹配 abc=abc 或
		\1代表分组1匹配的文本。有些与此正则表达式流派支持 多于9的分组	def=def, 而不是 abc=def 或 def=abc
	\10 到 \99	反向引用, 分组 10 到 99	
	\g{1}到 \g{99}	Perl 语法中,反向引用语法优化 ^①	避免出现歧义,同时用负数分组还能倒序
	\g{-1}, \g{-2}, etc.	倒数第1个分组,倒数第2个分组,…	引用。
	(? <name>regex)</name>	命令分组	命名分组的最大好处是反向引用时不用再怕弄错分组了。

[®]如果想实现类似<mark>(.)\1</mark>的效果,若紧跟的字符和分组号相同,如<mark>(.)\111</mark>,这样正则表达式引擎就不知所措,如果用 \g{1}11</mark>这种语法就不会有歧义,最重要的是这种语法或以用负数分组号倒序选用分组。

8 3 高级语法

(续表)

特性	语法	描述	举个栗子
	\k <name></name>	反向引用命令分组,Perl 中也可以使用\g{name}。	
	\`	正则表达式匹配部分之前的字符串, Perl 语言中也作 \${^PREMATCH}	
	\&	正则表达式匹配的部分,Perl语言中也作 \${^MATCH}	
	\'	正则表达式匹配部分之后的字符串, Perl 语言中也作 \${^POSTMATCH}	

3 高级语法 Advanced Syntax

之所以本文档中称这些正则为"高级语法",一是有些不常用,二是有些语法不太好理解,故有此一说。

特性	语法	描述	举个栗子
模式修饰符	(?i)	打开忽略大小写模式,之后的模式不分大小写。模式修饰符有 i, s, m, x 四种,分别是忽略大小写(IgnoreCase)、单行模式(Singleline)、多行模式(Multiline)和注释模式	(?i)te(?-i)st 匹配 TEst, 而不匹配 TEST
	(?-i)	关闭忽略大小写模式,之后的模式不分大小写	
	(?s)	打开单行模式,之后的模式不支持多行	默认情况下. 是不匹配换行的,打开该模
	(?-s)	关闭单行模式,之后的模式支持多行	式后,待匹配的字符将为视为"一行"。
	(?m)	打开多行模式, 之后的模式支持多行	
	(?-m)	[^] 和 <mark>\$</mark> 匹配行首和行尾	
	(?x)	打开宽松和注释模式	打开该模式后,可以在正则表达式中插和
	(?-x)	关闭宽松和注释模式	空白和换行,使正则表达式可读性增强。
	(?i-sm)	打开i和m模式,关闭s模式	以上几种模式可以组合使用
	(?i-sm:regex)	在 (?i-sm:regex) 子模式内打开 i 和 m 模式,关闭 s 模式	ハエノUTF (矢人 可)ハユ ロ 灰 / I
注释	(?#comment)	注释	

3 高级语法

(续表)

特性	语法	描述	举个栗子
零宽断言	(?=Regex)	肯定顺序环视(Negative Lookahead) 子表达式 <u>能</u> 够匹配 <u>右侧</u> 文本,含以下三种些类正则被 称" 环视 (Lookaround, Lookahead 和 Lookbehind 统称 为 Lookaround)", 也称为" 零宽断言 "(Zero-Length Assertions)	\b\w+(?=ing\b), 匹配以 ing 结尾的单词的前面部分(除了 ing 以外的部分)
	(?!Regex)	否定顺序环视(Positive Lookahead) 子表达式 <u>不能</u> 匹配 <u>右侧</u> 文本	(?<=\bre)\w+\b 会匹配以 re 开头的单词的后半部分(除了 re 以外的部分) 又, (?<=\s)\d+(?=\s) 匹配以空白符间隔的数字(再次强调,不包括这些空白符)
	(?<=regex)	肯定逆序环视(Positive Lookbehind) 子表达式 <u>能</u> 够匹配 <u>左侧</u> 文本	\d{3}(?!\d) 匹配三位数字,而且这三位数字的后面不能是数字
	(? regex)</td <td>否定逆序环视(Negative Lookbehind) 子表达式 <u>不能</u> 匹配 <u>左侧</u> 文本</td> <td>(?<!--[a-z])\d{7} 匹配前面不是小写字母的七位数字<br-->又, (?<=<(\w+)>).(?=<\/\1>) 匹配不包含属性的简单 HTML 标签内里的内容</td>	否定逆序环视(Negative Lookbehind) 子表达式 <u>不能</u> 匹配 <u>左侧</u> 文本	(? [a-z])\d{7} 匹配前面不是小写字母的七位数字<br 又, (?<=<(\w+)>).(?=<\/\1>) 匹配不包含属性的简单 HTML 标签内里的内容

(续表)

特性	语法	描述	举个栗子
固化分组	(?>regex)	贪婪子表达式,也称"固化分组",使用它可以加快匹配失败的速度,如 Subject 这个字符串,现用 ^\w: 对其进行匹配,正则表达式引擎发现 Subject 不匹配,就会试图匹配Subjec,一直尝试到 S,发现都不匹配才得出无法匹配的结论。如果使用固化分组 ^(?>\w+):,它会直接试图使用\w+ 去匹配 Subjec 字符串,而不会一一回溯,发现\w+ 后面没有:,立即报告失败。	如果字符串中没有第二个 x 的时候, x(?>\w+)x 要比 x\w+x 高效得多

4 举些例子吧! Regex Examples

Email 地址

^[a-zA-Z0-9_.+-]+@[a-zA-Z0-9-]+\.[a-zA-Z0-9-.]+\$ 匹配形如 WisdomFusion@gmail.com 的邮箱地址。

日期

^\d{4}\-(0?[1-9]|1[012])\-(0?[1-9]|[12][0-9]|3[01])\$ 匹配形如 yyyy-mm-dd 格式的日期。

非零负整数

^\-[1-9][0-9]*\$ 匹配如 -2, -1024, ...之类的非零负整数。

匹配浮点数

[-+]?([0-9]*\.[0-9]+|[0-9]+). 匹配如 3.1415926 的浮点数(带小数位的)。

去除重复行

查找^(.*)(\r?\n\1)+\$, 替的为\1。

匹配用户名

^[a-z0-9 -]{3,16}\$

网址 URL

 $\hat{(}_{a-z}.]+)\.([a-z].]{2,6})([\w\.-]*)*/?$

IPv4 地址

^(?:(?:25[0-5]|2[0-4][0-9]|[01]?[0-9][0-9]?)\.){3}(?:25[0-5]|2[0-4][0-9]|[01]?[0-9][0-9]?)\$

HTML 标记

 $<([a-z]+)([^<]+)*(?:>(.*)<\/1>|\s+\/>)$

UBB 代码清理

把\[/?(?:font|size)([^\]]+)?\] 替换为空。

汉字

[^u4E00-u9FA5] 或 [一-図]

5 正则表达式"流派" Regex Flavors

在标准制定之前,各家正则自成一派,不同工具不同编程语言各不相干。为了理清正则表达式的混乱局面,POSIX[®]把各种常见的流派分为两大类: Basic Regular Expressions(BREs) 和 Extended Regular Expressions(EREs)。POSIX 程序必须支持其中的任意一种标准。

[®]诞生于 1986 年的 POSIX 是 Portable Operating System Interface (可移植操作系统接口)的缩写,这是一系列标准,确保操作系统之间的移植性。

表3(POSIX 正则表达式流派概览)中列表出两大流派对正则表达式特性支持的情况,随着文档的完善和丰富,特性的总结将会更加全面。

正则表达式特性	BREs	EREs
点、^、\$、[]、[^]	✓	✓
"任意数目"量词	*	*
+ 和? 量词		+ ?
区间量词	\{m,n\}	{m,n}
分组	\{\}	
量词可否作用于括号	✓	✓
反向引用	\1 到\9	
多选结构		✓

表 3: POSIX 正则表达式流派概览

标准定了,流派也有了,那么各家支持的如何呢?表4(若干工具的正则表达式流派对比)作了简单的对比,可以看出,不同的工具和编程语言,虽没有统一语言,但相差不大,在具体使用某种工具或语言时需要单独了解和掌握。

特性	grep	egrep	GNU Emacs	Tcl	Perl	.NET	Java
*、^、\$、[]	✓	✓	✓	1	✓	✓	✓
? +	\? \+ \	? +	? + \	? +	? +	? +	? +
分组	\(\)	()	\(\)	()	()	()	()
(?:)					✓	✓	✓
单词分界符		\<\>	\<\>, \b\B	\n\M\y	\b\B	\b\B	\b\B
\w, \W		✓	✓	1	✓	✓	✓
反向引用	✓	✓	✓	1	✓	✓	✓

表 4: 若干工具的正则表达式流派对比

6 应用场景 Application Scenarios

6.1 正则表达式工具箱 Regex Toolbox

总有一款适合你, Windows 下的记事本太鸡肋, Word 处理方式主要是"通配符"而不是正则表达式。

JGsoft RegexBuddy

JGsoft 开发的一个强大的正则表达式测试工具,这款是正则测试界最最强大的工具了,没有之一,要墙裂向大家推介的哦!◎

图1中所示, ①正则表达式区域, ②替换字符区域, ③暂存使用的正则表达式以备后用, ④待测试的文字, ⑤替换后的文字。没有标注的区域还有一大堆很贴心的正则表达式创建功能, 比如不同语言的选择、模式的开关、正则表达式库等等, 正如其名"正则表达式好兄弟", 我平时更喜欢"正则基友"这个简称, ⑤建议安装长期占有之。




图 1: RegexBuddy 界面

6.1 正则表达式工具箱 17

JGsoft PowerGREP

PowerGREP RegexBuddy 的兄弟软件,同是 JGsoft 开发,是 grep 在 Windows 平台的实现和增强。

Debuggex

https://www.debuggex.com/

grep

grep

UltraEdit, Notepad++

UltraEdit, Notepad++

Vim

编辑器之神 Vim

GNU Emacs

GNU Emacs 中正则表达式异常强大,除了基本的正向正则查找 C-M-s 、反向正则查找 C-M-r 、正则替换 M-x replace-regexp、查询式正则替换 M-x query-replace-regexp、保留行 M-x keep-lines、删除行 M-x flush-lines、...等等,Emacs 正则表达式替换时还能直接执行 LISP[®] Form[®]。详见6.2.13。




图 2: GNU Emacs 中 RE-Builder 模式

[®]出生自 1958 年,但目前仍很活跃的一门编程语言,尤其在 AI 领域中。

^②简言之:可以直接执行 LISP 代码,利用强大的编程语言提供的函数方法去处理文本。

6.1 正则表达式工具箱 19

sed & awk

sed and awk

6.2 应用案例 Application Cases

6.2.1 Perl 正则表达式王国

6.2.2 Python

Python

6.2.3 PHP PCRE

PHP 中使用 PCRE^①

6.2.4 sed & awk

sed

awk

6.2.5 grep

grep, egrep, fgrep

6.2.6 Swift

Apple Swift

6.2.7 Java

6.2.8 .NET Framework 正则表达式

.NET Framework 正则表达式

^①PCRE, Perl Compatible Regular Expressions

6.2 应用案例 21

6.2.9 JavaScript

6.2.10 Adobe Dreamweaver 表格处理

6.2.11 VBA 中使用正则表达式

VBA[®]是不直接支持正则表达式的,需要借助 VBScript RegExp Object,具体请参考Microsoft Beefs Up VBScript with Regular Expressions。

```
Sub IndentParaWithRegEx()
   ' PowerPoint VBA 批量给指定字符开头段落加动画
   Dim oSld As Slide
   Dim oShp As Shape
   Dim i As Integer
   ' 正则相关变量
   Dim regx As Object, oMatch As Object
   strPattern = "^开头字符串"
   Set regx = CreateObject("vbscript.regexp")
   With regx
11
       .Global = True
12
       .IgnoreCase = True
13
       .Pattern = strPattern
   End With
15
16
   For Each oSld In ActivePresentation.Slides
17
       For Each oShp In oSld.Shapes
18
           If oShp.HasTextFrame Then
19
              If oShp.TextFrame2.HasText Then
20
                   With oShp.TextFrame2.TextRange
21
```

^①Visual Basic for Application,Microsoft Office 套件宏语言。

22 7 后记

```
For i = 1 To .Paragraphs.Count
22
                           With .Paragraphs(i)
23
                                '可能会出现多个匹配项的
24
                               If (regx.Test(.Text) = True) Then
25
                                   .ParagraphFormat.FirstLineIndent = 0
26
                               End If
27
                           End With
28
                       Next i 'para
29
                   End With
30
               End If 'has text
31
           End If 'has textframe
32
       Next oShp
33
   Next oSld
   End Sub
```

6.2.12 GREP for Adobe InDesign

6.2.13 神的编辑器 GNU Emacs 之正则神器

7 后记

后记